# Spark-2. 3. 2-bin-hadoop2. 6 镜像构建

# 一、 实现目的

基于容器技术, 搭建 Spark-Hadoop 开发环境, 以供开发人员快速掌握并应用到实际开发中, 有关 Spark 的优点等知识这里不再赘述。暂且把优点总结如下:

- 1) 技术积累
- 2) 省时省力省钱

# 二、 环境准备

1) sequenceiq/docker-spark 源码

下载 sequenceiq/ docker-spark 镜像构建源码,下载命令如下:

git clone https://github.com/sequenceiq/docker-spark

2) sequenceiq/hadoop-docker:2.6.0 官网镜像

docker pull sequenceiq/hadoop-docker: 2.6.0

3) spark-2.3.2-bin-hadoop2.6.tgz




4) jdk-8u25-linux-x64.tar.gz

请自行下载。

# 三、 镜像构建

## 1) 目录结构

基础目录结构如下图所示:



其中, docker-spark 为 sequenceiq/docker-spark 源码目录, Dockerfile 及 yarn-site.xml 如下附件。



#### 2) 构建命令

docker build --rm -t kngines/spark:2.3.2.

### 3) 结果输出



### 4) 创建容器

docker run -it -p 8088:8088 -p 8042:8042 -p 4040:4040 -h sandbox

kngines/spark:2.3.2 bash

### 5) 运行模式

1. Local 模式命令

spark-shell --master local --driver-memory 1g --executor-memory 1g --executor-cores

1

2. Yarn 模式命令

spark-shell --master yarn --deploy-mode client --driver-memory 512m --executor-

memory 512m --executor-cores 1

## 6) 运行效果

# 四、 测试运行

#### 1) 简单测试

```
scala> sc.parallelize(1 to 1000).count()
res1: Long = 1000
scala> [
```

### 2) 复杂测试 (Hadoop-Spark)

```
bash-4.1# ls -l
total 4
-rw-r--r--. 1 root root 37 Jan 22 00:48 hello.txt
bash-4.1# hadoop fs -mkdir -p /spark
bash-4.1# hadoop fs -put hello.txt /spark
```

```
bash-4.1# hadoop fs -cat /spark/out/p*
(jump,5)
(you,2)
(i,2)
```

#### 说明:

sc 是 SparkContext 对象,提交 spark 程序的入口
textFile("/spark/hello.txt")是从 hdfs 中读取数据
flatMap(\_.split(" "))先 map 再压平
map((\_,1))将单词和 1 构成元组
reduceByKey(\_+\_)按照 key 进行 reduce,并将 value 累加
saveAsTextFile("/spark/out")将结果写入到 hdfs 中
相关命令:

```
hadoop fs -mkdir -p /spark
hadoop fs -put hello.txt /spark
hadoop fs -cat /spark/out/p*
```

## 五、 Web UI

### 3) Spark Web UI



